

Limpeza de dados aplicada à otimização de funções de kernel para máquinas de vetores de suporte

Jose Augusto dos Santos Silva¹

¹Instituto de Computação – Universidade Federal de Alagoas (UFAL)
Av. Lourival Melo Mota, S/N – Cidade Universitária, Maceió – AL, 57072-970

Abstract. *This work focuses on investigating the importance of data cleaning as a conditioning vector for machine learning. Through a brief analysis of a data set, replacing the zeros present with the average of the data set, in each column, can benefit machine learning models in achieving better quality metrics. The approach uses python and pandas to replace the zeros with the arithmetic mean before the training and validation stages. This work uses the Pima dataset as an example. This approach was used in the master's research base code, which is based on the undergraduate course completion work.*

Resumo. *Este trabalho tem como foco investigar a importância da limpeza de dados como vetor condicionante para a aprendizagem de máquina. Através de uma breve análise de um conjunto de dados, a substituição dos zeros presentes pela média do conjunto de dados, em cada coluna, pode beneficiar os modelos de aprendizagem de máquina no alcance de melhores métricas de qualidade. A abordagem usa python e pandas para substituir os zeros pela média aritmética antes das etapas de treino e validação. Este trabalho utiliza o conjunto de dados Pima foi utilizado como exemplo. Tal abordagem foi utilizada no código base da pesquisa do mestrado, que é baseada no trabalho de conclusão de curso da graduação.*

1. Breve Histórico da Pesquisa e Introdução ao Trabalho

Aprendizado de máquina, um subconjunto da inteligência artificial, foca no desenvolvimento de modelos matemáticos que permitem que computadores aprendam e tomem decisões a partir do uso de dados. Em vez de serem explicitamente programados para executar uma tarefa, esses modelos usam métodos estatísticos para identificar padrões a partir dos dados e fazer previsões.

De maneira central a este campo está o desenvolvimento de algoritmos capazes de modelar relações não lineares pelo uso dos dados. Um desses tradicionais e potentes modelos são as máquinas de vetores de suporte (SVMs), com raízes na teoria do aprendizado estatístico, que são modelos de aprendizagem supervisionada que se destacam em tarefas de classificação ao encontrar o melhor hiperplano que separa as classes distintas de um conjunto de dados rotulado.

SVMs têm notória popularidade em diferentes cenários devido a sua habilidade de generalização e de lidar com funções de decisão não lineares. Um dos fatores críticos que influenciam a sua função de decisão para lidar com problemas não lineares é a escolha da função de kernel, que representa o resultado do produto interno no espaço de alta dimensão onde os dados são implicitamente transformados para que modelos lineares possam encontrar funções de decisão não lineares.

O código base da pesquisa do mestrado, que nasceu no trabalho de conclusão de curso (TCC) da graduação, explora a viabilidade de funções racionais como funções de kernel, que são funções definidas pelo quociente entre dois polinômios, otimizadas pelo uso da Evolução Diferencial. Deste modo, o objetivo principal da pesquisa do mestrado é construir uma metodologia de aprendizado automatizado de funções de kernel modeladas por funções racionais para investigar a viabilidade de obter desempenho comparável em relação a kernels tradicionais da literatura. De maneira mais específica, este trabalho foca no impacto da limpeza dos dados antes de utilizar a metodologia base da pesquisa de mestrado.

Os experimentos foram conduzidos utilizando o conjunto de dados Pima e os resultados mostram que os experimentos com as funções de kernel racionais somados com a limpeza dos zeros do conjunto Pima alcançaram, em média, acurácia balanceada maior em relação aos experimentos com as funções de kernel racional sem a limpeza dos zeros, tanto em treino quanto em teste. Tal resultado demonstra o potencial da limpeza dos dados antes da execução dos códigos base da pesquisa do mestrado.

Este trabalho utilizou como base os conhecimentos de [Schölkopf and Smola 2002] para o entendimento das SVMs, [Blum and Roli 2003] para vislumbrar a área de otimização combinatória, incluindo meta-heurísticas de otimização. [Koch et al. 2012] para compreender o universo de otimização e ajuste dos parâmetros das SVMs. [Dioşan et al. 2012] é um ótimo trabalho para entender como meta-heurísticas evolucionárias de otimização podem ser utilizadas para otimizar funções de kernel. Já [Roman et al. 2021] desenvolveu uma base sólida para analisar os diversos fatores que influenciam o desempenho das SVMs associadas, além de desenvolver, também, uma metodologia de aprendizado de novas funções de kernel pelo uso de meta-heurísticas. Por fim, e não menos importante, [Silva et al. 2023] é o TCC utilizado como base para este projeto de ciência de dados e também a base da pesquisa de mestrado citada neste trabalho.

2. Algumas limitações apontadas no TCC e por que atacar a limpeza dos zeros

No final do TCC, foi apresentado um conjunto de limitações e trabalhos futuros possíveis para avançar durante a pesquisa de mestrado. As principais limitações foram: a utilização de um único conjunto de dados para testar a abordagem proposta, ajuste da função de aptidão da Evolução Diferencial, ajuste da função de distância entre entradas do conjunto de dados e a limpeza dos dados antes de executar o código.

A limpeza dos dados foi atacada pois o estágio de tratamento e limpeza de dados é um precursor crítico para a implantação de algoritmos de AM, especialmente os automáticos, como a proposta da pesquisa do mestrado. Somente a etapa de transformação (normalização, por exemplo) dos dados não é suficiente. Dados crus geralmente apresentam inconsistências, erros, valores faltantes e potenciais outliers que, se não forem tratados, podem resultar em resultados não confiáveis e enganosos. Por exemplo, há 227 valores iguais a zero nas instâncias da coluna que representa a largura da pele do tríceps do conjunto de dados Pima, o que é fisicamente impossível. Portanto, a construção de um estágio de limpeza de dados se mostra necessária em trabalhos futuros.

3. Conjunto de Dados Pima

O conjunto de dados Pima é uma coleção de registros médicos dos índios Pima do Arizona, utilizada principalmente para pesquisas sobre diabetes e frequentemente utilizado como benchmark para projetos de ciência de dados e aprendizagem de máquina. Este conjunto contém informações como o número de gestações (NG), teste oral de tolerância à glicose (TOTG), insulina sérica (IS), espessura da pele do tríceps (EPT), idade (Id), pressão sanguínea diastólica (PSD), índice de massa corporal (IMC) e estimativa de risco à diabetes baseada no histórico familiar (ERD).

Estatística	NG	TOTG	IS	EPT	Id	PSD	IMC	ERD
Média	3,84	120,89	79,80	20,54	33,24	69,10	31,99	0,471
Variância	11,35	1022,25	13281,18	254,47	138,30	374,65	62,16	0,110
Mínimo	0,00	0,00	0,00	0,00	21,00	0,00	0,00	0,078
1º Quartil	1,00	99,00	0,00	0,00	24,00	62,00	27,30	0,244
2º Quartil	3,00	117,00	30,50	23,00	29,00	72,00	32,00	0,372
3º Quartil	6,00	140,25	127,25	32,00	41,00	80,00	36,60	0,626
Máximo	17,00	199,00	846,00	99,00	81,00	122,00	67,10	2,42

Figure 1. Análise descritiva do conjunto de dados Pima

Ainda, foi possível observar valores iguais a zero em algumas colunas que normalmente não fazem sentido prático e que podem ser erros de leitura do equipamento de coleta e análise ou erros de processamento. As colunas IMC, EPT, PSD e TOTG apresentaram tais valores, ensejando a sua correção antes da execução do código base da pesquisa.

4. Metodologia

4.1. Resumo do TCC como base para a pesquisa do mestrado

A ideia principal é melhorar o desempenho de SVMs ao substituir as funções de kernel tradicionais por uma função de kernel que é modelada baseada em uma função polinomial. Uma função racional é uma função que é a razão entre dois polinômios, como mostra a equação abaixo:

$$f(x) = \frac{P(x)}{Q(x)}$$

e expandindo os polinômios $P(x)$ e $Q(x)$ temos o que se segue:

$$f(x) = \frac{a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x + a_0}{b_m x^m + b_{m-1} x^{m-1} + \dots + b_1 x + b_0}.$$

Porém, ao introduzir $f(x)$ como modelo para uma função de kernel, surgem dois pontos como destaque: como definir os valores de x que são as entradas para $f(x)$ e como encontrar os coeficientes de cada polinômio. Para a primeira questão, basta definir

$$K(x, y) = f(D(x, y))$$

como a função de kernel calculada para os vetores x e y do conjunto de dados. Para a segunda questão, basta utilizar uma meta-heurística de otimização (como a Evolução Diferencial, utilizada na pesquisa) associada a uma função de aptidão bem definida.

4.2. Correção dos Dados

Para identificar as colunas que precisavam ser corrigidas, foi utilizado a linguagem python associada às bibliotecas pandas e pandas-profiling. Foi utilizado a funcionalidade de ProfilingReport do pandas-profiling, que gerou uma página html com alguns pontos importante sobre as distribuições dos dados.

Na investigação da página html gerada, observou-se os valores iguais a zero em colunas que, na prática, não fazem sentido ter seu valor igual a zero. Geralmente isso ocorre em dados faltantes ou não registrados, e também podem vir de erros de coleta ou processamento. As colunas identificadas são: IMC, EPT, PSD e TOTG.

```
1 import pandas as pd
2
3 df = pd.read_csv('datasets/pima/pima2.tsv.gz', compression='gzip', header=0, sep='\t')
4
5 columns_to_fix = ['plasma glucose', 'Diastolic blood pressure', 'Triceps skin fold thickness', 'Body mass index']
6
7 for column in columns_to_fix:
8     m = df.loc[(df['target'] == 0) & (df[column] != 0)][column].values.mean()
9     df.loc[(df['target'] == 0) & (df[column] == 0), column] = m
10
11 m = df.loc[(df['target'] == 1) & (df[column] != 0)][column].values.mean()
12 df.loc[(df['target'] == 1) & (df[column] == 0), column] = m
13
14 df.to_csv('datasets/pima/pima.tsv.gz', sep='\t', compression='gzip', index=False)
```

Figure 2. Código que ajusta zeros das colunas citadas

Para corrigir as colunas, foi utilizado o script em python da figura 2 que, primeiramente, lê o conjunto de dados. Depois, para cada coluna identificada como portadora de zeros inverossímeis, foi calculado a média dos valores diferentes de zero para cada coluna e classe (ter ou não ter diabetes). Em seguida, a média calculada foi atribuída aos valores iguais a zero da mesma coluna e classe.

4.3. Como comparar o antes e depois da limpeza?

Esta parte é relativamente simples, bastando executar o código base da pesquisa com os mesmos parâmetros de execução. Além do mesmo conjunto de dados, que neste trabalho será o Pima, tais parâmetros são: C , que representa o parâmetro de regularização das SVMs; G , que representa a quantidade de coeficientes em cada polinômio constituinte da função racional $f(x)$, P , que representa o tamanho da população da meta-heurística Evolução Diferencial; e N , o número de gerações da Evolução Diferencial.

Os valores para P e N foram fixados, respectivamente, em $P = 30$ e $N = 40$. Os valores para C e G variaram conforme as os valores apresentados nas tabelas 1 e 2 da seção 5. Tais valores não são aleatórios: foram os melhores parâmetros encontrados nas execuções do TCC e foi utilizado como ponto de partida para a comparação pois não utilizaram a abordagem de limpeza dos zeros. Cada combinação de C e G foi executada trinta vezes, cada uma com uma semente aleatória diferente. A mesma semente foi executada sem e com a abordagem de limpeza dos zeros. O valor de cada métrica das tabelas supracitadas é a média das trinta execuções.

5. Resultados

As tabelas 1 e 2 mostram os resultados para as cinco melhores configurações encontradas no TCC que serviu de base para a pesquisa do mestrado. C representa o parâmetro de

regularização da SVM, G representa a quantidade de coeficientes em cada função de kernel racional, F representa o valor da função de aptidão (no contexto do algoritmo de Evolução Diferencial) da configuração associada a C e G .

BAS^{tr} , ITR^{tr} e NSV^{tr} representam, respectivamente, as métricas de acurácia balanceada em treino, quantidade normalizada de iterações para a convergência da SVM em treino e quantidade normalizada de vetores de suporte utilizados em treino. Já BAS^{te} , ITR^{te} e NSV^{te} representam, respectivamente, as métricas de acurácia balanceada em teste, quantidade normalizada de iterações para a convergência da SVM em teste e quantidade normalizada de vetores de suporte utilizados em teste.

O valor da função de aptidão, F , é calculado como $F = BAS^{tr} - \alpha \times (ITR^{tr} + NSV^{tr})$, onde α é um valor fixo que é resultado da razão entre o número de divisões do conjunto de treino e o tamanho do número de treino. Foi definido desta forma para que o peso dado às métricas ITR^{tr} e NSV^{tr} seja menor do que a importância dada à métrica de acurácia balanceada BAS^{tr} .

C	G	F	BAS^{tr}	ITR^{tr}	NSV^{tr}	BAS^{te}	ITR^{te}	NSV^{te}
128.0	3	0.7391	0.7432	0.1224	0.5152	0.7180	0.1500	0.4943
8.0	4	0.7390	0.7430	0.1202	0.5045	0.7156	0.1570	0.4928
2048.0	3	0.7385	0.7421	0.0811	0.4649	0.7181	0.1033	0.4485
32.0	3	0.7381	0.7418	0.0870	0.4777	0.7124	0.1166	0.4712
32.0	4	0.7375	0.7416	0.1229	0.5166	0.7142	0.1726	0.5044

Table 1. Resultados para o conjunto Pima sem a limpeza dos zeros

C	G	F	BAS^{tr}	ITR^{tr}	NSV^{tr}	BAS^{te}	ITR^{te}	NSV^{te}
8.0	4	0.7600	0.7649	0.1748	0.5697	0.7435	0.2356	0.5553
32.0	4	0.7583	0.7637	0.2306	0.5973	0.7389	0.3110	0.5884
32.0	3	0.7593	0.7635	0.1350	0.5167	0.7430	0.1796	0.5095
2048.0	3	0.7577	0.7625	0.1799	0.5626	0.7398	0.2404	0.5560
128.0	3	0.7566	0.7617	0.1979	0.5803	0.7373	0.2631	0.5729

Table 2. Resultados para o conjunto Pima com a limpeza dos zeros

Comparando diretamente as duas tabelas, é possível notar que as métricas de quantidade de iterações e quantidade de vetores de suporte são maiores para o experimento com a limpeza dos dados, o que significa dizer que, respectivamente, o algoritmo demora um pouco a mais para treinar e que a função de decisão utiliza mais alguns vetores de suporte para calcular a predição.

No entanto, o custo de treino e predição no experimento com a limpeza dos dados não são maiores em vão: as métricas de acurácia balanceada, tanto em treino quanto em teste, são, em média, superiores às métricas de acurácia balanceada do experimento sem a limpeza dos dados. Na prática, um modelo mais assertivo devidamente validado é preferível em relação a um modelo menos assertivo, ainda que tenha um custo ligeiramente maior para treinar e calcular a predição.

6. Conclusões

O impacto da limpeza de dados nos resultados da aprendizagem automática é historicamente reconhecido com o positivo. A investigação indica que a limpeza de dados, que envolve a remoção de erros e inconsistências, é parte fundante na construção de modelos robustos de aprendizagem de máquina automática. São capazes de melhorar as métricas de aprendizagem de máquina e pode reduzir o enviesamento, conduzindo a desempenhos de modelos mais confiáveis.

Por conseguinte, este projeto para a disciplina de ciência de dados evidencia a importância da limpeza de dados como uma etapa primordial no código base da pesquisa de mestrado e que pode influenciar significativamente a eficácia das SVMs associadas às funções de kernel racionais, logrando êxito na comparação das abordagens antes e depois da limpeza dos zeros ao atingir uma acurácia balanceada maior depois da limpeza.

7. Próximos Passos

É preciso investigar as limitações previamente apontadas, como a escolha de uma função de distância adequada, a estruturação de uma função de aptidão também adequada e a execução do código base da pesquisa em uma variada gama de conjuntos de dados para verificar a efetividade da metodologia apresentada, bem como o impacto da limpeza dos dados antes de introduzi-los na execução.

Ainda, faz-se necessário investigar a validade das condições necessárias e suficientes do teorema de Mercer, que garantem que uma determinada função seja, de fato, uma função de kernel. Isto é fundamental para que se garanta que a função represente um mapeamento implícito de um produto interno e assegurar que o problema de otimização intrínseco do treino das SVMs é convexo, isto é, solucionável com eficiência.

References

- Blum, C. and Roli, A. (2003). Metaheuristics in combinatorial optimization: Overview and conceptual comparison. *ACM computing surveys (CSUR)*, 35(3):268–308.
- Dioşan, L., Rogozan, A., and Pecuchet, J.-P. (2012). Improving classification performance of support vector machine by genetically optimising kernel shape and hyperparameters. *Applied Intelligence*, 36:280–294.
- Koch, P., Bischl, B., Flasch, O., Bartz-Beielstein, T., Weihs, C., and Konen, W. (2012). Tuning and evolution of support vector kernels. *Evolutionary Intelligence*, 5:153–170.
- Roman, I., Santana, R., Mendiburu, A., and Lozano, J. A. (2021). In-depth analysis of svm kernel learning and its components. *Neural Computing and Applications*, 33(12):6575–6594.
- Schölkopf, B. and Smola, A. J. (2002). *Learning with kernels: support vector machines, regularization, optimization, and beyond*. MIT press.
- Silva, J. A. d. S. et al. (2023). Otimizando funções de kernel racionais para máquinas de vetores de suporte.